

Classificação Automática de Imagens Fluoroscópicas de CPRE com *Deep Learning*

MECD, Grupo3

Beatriz Peixoto (pg59996), Diogo Miranda (pg60001), Martim Félix (pg58753), Sandra Cerqueira (pg60016)

Abstract.

A Colangiopancreatografia Retrógrada Endoscópica (CPRE) é um procedimento intervencionista complexo cujos resultados dependem criticamente da interpretação de imagens fluoroscópicas em tempo real. Este trabalho apresenta uma solução de deep learning para a classificação automática dessas imagens em quatro categorias clínicas: *Biliary Leaks*, *Lithiasis*, *Stricture* e *Normal*, utilizando o dataset MIQR-CC como base. Foram exploradas e comparadas múltiplas arquiteturas, incluindo redes convolucionais e Vision Transformers, com recurso a *transfer learning*, técnicas de aumento de dados e ponderação de classes para mitigar o desequilíbrio existente no *dataset*. A avaliação seguiu o protocolo de *hold-out* definido no artigo de referência (70/15/15), sendo o F1-score macro a métrica principal. Os modelos desenvolvidos foram comparados com a *baseline* reportada (F1 = 0.738, EfficientNet-B7). A interpretabilidade foi assegurada através de mapas Grad-CAM, permitindo validar qualitativamente o foco das predições nas regiões anatomicamente relevantes.

Keywords: Deep Learning · CPRE · Classificação de Imagem Médica · Transfer Learning · Ensemble · VAE · Grad-CAM

1 Introdução

A Colangiopancreatografia Retrógrada Endoscópica (CPRE) é um procedimento médico utilizado no diagnóstico e tratamento de patologias pancreatobiliares através de imagens fluoroscópicas obtidas em tempo real. A interpretação destas imagens é particularmente desafiante devido ao baixo contraste, presença de ruído, artefactos radiológicos e elevada semelhança visual entre diferentes patologias, tornando a análise dependente da experiência clínica do especialista. Neste contexto, técnicas de *Deep Learning* têm vindo a demonstrar potencial como ferramentas de apoio à decisão clínica em tarefas de classificação automática de imagem médica. Recentemente, o *dataset* MIQR-CC disponibilizou um conjunto de imagens fluoroscópicas de CPRE anotadas por especialistas e organizadas em quatro categorias principais: *Biliary Leaks*, *Lithiasis*, *Stricture* e *Normal*. O trabalho original associado ao *dataset* avaliou diferentes arquiteturas de *Deep Learning* tais como: MobileNetV2; EfficientNet-B7; ResNet50; DenseNet121 e DeiT3-Small, estabelecendo uma *baseline* de desempenho para a tarefa de classificação multi-classe, alcançando um F1-score macro de 0.738 no conjunto de teste com o modelo EfficientNet-B7.

Apesar dos resultados promissores apresentados no trabalho original, a classificação automática de imagens de CPRE continua a apresentar desafios significativos, sobretudo devido ao forte desequilíbrio entre classes e à elevada variabilidade visual das imagens fluoroscópicas. O presente trabalho tem como objetivo desenvolver e otimizar um pipeline de *deep learning* para a classificação automática de imagens de CPRE, procurando igualar ou superar a *baseline* reportada. As principais contribuições incluem a análise do desequilíbrio de classes, a exploração de múltiplas arquiteturas com *fine-tuning*, a aplicação de estratégias de mitigação do desequilíbrio, e a geração de visualizações Grad-CAM para interpretabilidade clínica.

2 Dataset e Desafio Principal

2.1 Descrição do Dataset

O dataset utilizado é o MIQR-CC (*Multimodal Image Quality and Risk in ERCP and Colonoscopy*), disponibilizado publicamente por Andrade et al. [1]. É composto por 19.317 imagens fluoroscópicas processadas, provenientes de 1.602 pacientes, das quais 5.519 se encontram anotadas por dois gastroenterologistas experientes e revistas por um clínico sênior. As imagens encontram-se organizadas em quatro classes diagnósticas: *Biliary_Leaks*, *Lithiasis*, *Stricture* e *Normal*. O *split* treino/validação/teste foi definido pelos autores com proporção 70/15/15, estratificado ao nível do paciente, garantindo que todas as imagens do mesmo doente pertencem ao mesmo subconjunto e prevenindo *data leakage*.

2.2 Distribuição dos Dados e Métrica Principal

A Tabela 1 apresenta a distribuição de imagens por classe e subconjunto. O *dataset* é claramente desequilibrado: *Lithiasis* é a classe dominante, representando cerca de 47% das imagens de treino, enquanto *Biliary_Leaks* constitui a classe minoritária, com apenas 110 imagens no treino e 17 no teste. Este desequilíbrio constitui um desafio importante para os modelos de *Deep Learning*, uma vez que estes tendem naturalmente a favorecer as classes maioritárias durante o treino. Consequentemente, métricas como *accuracy* podem produzir resultados enganadores, mascarando desempenhos reduzidos nas classes menos representadas.

Por esse motivo, a principal métrica utilizada neste trabalho foi o **F1-score macro**, seguindo o protocolo definido no artigo original [1]. Esta métrica atribui igual importância a todas as classes, independentemente da sua frequência, sendo particularmente adequada em cenários médicos desbalanceados. Além disso, permite uma comparação direta com a *baseline* reportada pelos autores, correspondente a um F1-score macro de 0.738.

Tabela 1. Distribuição de imagens por classe e subconjunto.

Classe	Treino	Validação	Teste
<i>Biliary_Leaks</i>	110	24	17
<i>Lithiasis</i>	505	98	123
<i>Normal</i>	197	59	43
<i>Stricture</i>	255	53	84

3 Metodologia

Como ponto de partida, foram reproduzidos localmente todos os modelos disponibilizados no repositório oficial de Andrade et al. [2], seguindo o *pipeline* de pré-processamento e o *split* treino/validação/teste originais. Este passo permitiu verificar a reprodutibilidade dos resultados reportados e estabelecer uma *baseline* local de referência para comparação com as abordagens desenvolvidas subsequentemente. O desenvolvimento da solução seguiu então uma abordagem iterativa, com cinco fases distintas, cada uma incorporando lições aprendidas da anterior.

- **Abordagem 1: CLAHE e Pesos de Classe.** Foram aplicados CLAHE e pesos por classe na Focal Loss para lidar com o contraste variável e o desequilíbrio do *dataset*. Foi ainda feita uma alteração ao código original onde o parâmetro de rotação estava em graus em vez de radianos.
- **Abordagem 2: Modelos Especialistas.** Foram testados classificadores binários para lidar com classes problemáticas, nomeadamente *Biliary_Leaks* e a confusão *Stricture/Lithiasis*.
- **Abordagem 3: XGBoost sobre Embeddings.** Foi explorado o XGBoost como classificador sobre *features* extraídas por uma CNN pré-treinada.

- **Abordagem 4: Geração Sintética com VAE.** Foi implementado um Variational Autoencoder para gerar imagens sintéticas das classes minoritárias (Biliary_Leaks, Stricture e Normal), utilizadas para fazer um *oversampling* controlado do conjunto de treino e mitigar o desbalanceamento.
- **Abordagem 5: Ensemble.** A solução final combinou as previsões dos melhores modelos individuais por *soft voting*, reduzindo a variância e melhorando a robustez nas classes minoritárias.

4 Reprodução da *Baseline*

Tal como referido anteriormente, os 5 modelos do repositório oficial foram executados localmente seguindo o pipeline original, com o objetivo de verificar a reprodutibilidade dos resultados e estabelecer uma referência comparativa. A Tabela 2 apresenta os F1-scores macro obtidos no conjunto de teste localmente em comparação com os reportados pelos autores originais.

Tabela 2. F1-scores macro reproduzidos localmente vs. valores reportados por Andrade et al.

Modelo	Test F1-macro (nosso <i>baseline</i>)	Test F1-macro (Andrade et al.)
DeiT3-Small	0.361	0.158
DenseNet121	0.513	0.621
EfficientNet-B7	0.672	0.738
MobileNetV2	0.513	0.574
ResNet50	0.535	0.617

Os resultados reproduzidos diferem dos reportados, o que é atribuível a variações de *hardware* e aleatoriedade no treino. Dado que estas diferenças impossibilitam uma comparação direta e justa com os valores originais, as abordagens desenvolvidas nas secções seguintes têm como referência principal os **valores reproduzidos localmente**, sendo o objetivo superar o melhor resultado obtido nesta fase que foi dado pelo *EfficientNet-B7* com *F1-macro* de **0.672**.

5 Abordagens Experimentais

5.1 Pré-Processamento e Treino Ponderado

Esta abordagem procurou resolver três problemas identificados no *dataset*: contraste variável nas imagens de fluoroscopia, desbalanceamento entre classes. Para tal, foram aplicadas três estratégias sobre um modelo MobileNetV2: CLAHE para melhoria do contraste local, pesos por classe para penalizar erros nas classes minoritárias, e *random rotation* como *data augmentation*.

Durante a análise do código original, foi identificado um erro no parâmetro do *random rotation*, isto é, o valor estava definido como 15, mas a função *RandRotate* do MONAI espera radianos e não graus. Um valor de 15 radianos corresponde a rotações de aproximadamente 860°, introduzindo variações completamente irrealistas nas imagens durante o treino. O valor foi corrigido para 0.26 radianos, equivalente a aproximadamente 15°.

Apesar desta correção, os resultados no MobileNetV2 não melhoraram. O F1 Macro na validação desceu de 0.546 no *baseline* para ≈ 0.510 e no teste este decréscimo também se manteve tendo passado de 0.513 para 0.470. Assim, estas técnicas não trouxeram benefício para este problema, pelo que a abordagem foi descartada.

5.2 Modelos especialistas

Devido ao forte desbalanceamento do *dataset*, foi também desenvolvida uma abordagem específica para melhorar a deteção da classe *Biliary Leaks*. Esta classe era a menos representada no conjunto de

treino e, por isso, apresentava maior risco de ser confundida com as restantes classes pelos modelos multiclasse.

Para esse efeito, foi treinado um classificador binário especializado em distinguir *Biliary Leaks* de todos os outros casos, reformulando temporariamente o problema original de quatro classes numa tarefa binária: *Biliary Leaks* versus restantes classes. O objetivo era usar este modelo como mecanismo complementar de correção após a previsão base de um *ensemble* conservador. Quando a probabilidade atribuída pelo especialista à classe *Biliary Leaks* ultrapassava um determinado *threshold*, a previsão era substituída por essa classe.

Numa fase posterior, esta estratégia foi refinada no contexto da solução final descrita na Secção 5.5. O especialista para *Biliary Leaks* foi novamente treinado recorrendo não só às imagens reais disponíveis, mas também a imagens sintéticas. Foram ainda testadas variações adicionais, incluindo *hard-negative sampling* e *partial fine-tuning*, com o objetivo de tornar o especialista mais discriminativo e reduzir falsos positivos.

Para além disso, foi explorado um segundo especialista binário focado na confusão *Stricture/Lithiasis*, uma vez que esta era uma das principais fontes de erro observadas na matriz de confusão.

A integração final destes mecanismos no *ensemble* é discutida na Secção 5.5, onde se analisa o seu impacto real nas previsões finais e se justifica a escolha da solução definitiva.

5.3 XGBoost com Latent Features

Adicionalmente, foi explorada uma abordagem baseada na extração de representações latentes através de Autoencoders (AE) e Variational Autoencoders (VAE), utilizando posteriormente um classificador XGBoost. Foram testadas múltiplas variantes de Autoencoder convolucional, diferindo na profundidade do *encoder*, na resolução de entrada (128×128, 256×256 e 512×512), na função de ativação (ReLU vs LeakyReLU) e na função de perda, MSE, L1 e uma combinação de MSE com SSIM, esta última com o objetivo de privilegiar a fidelidade estrutural das reconstruções.

No que respeita ao VAE, foi adotada uma estratégia de especialização por classe, treinando um VAE distinto para cada patologia clínica. Cada imagem foi passada por todos os VAEs treinados, extraíndo de cada um o vetor latente. Os vetores resultantes foram concatenados, formando um único vetor de *features* utilizado como entrada para o classificador XGBoost.

Apesar das várias modificações introduzidas, os resultados mantiveram-se estáveis com valores de F1 Macro próximos de 0.30 no teste. O melhor desempenho foi obtido por um Autoencoder convolucional mais simples, com um F1 Macro de 0.325 no teste e uma *accuracy* de 45.7%. A estabilidade dos resultados ao longo das diferentes variantes sugere que a limitação não é arquitetural, mas sim inerente à própria abordagem. As representações latentes extraídas revelaram-se assim insuficientes para suportar uma classificação robusta, apresentando um desempenho inferior ao das restantes arquiteturas avaliadas neste trabalho.

5.4 Geração de Imagens com VAE

Face aos resultados das abordagens anteriores, observou-se que as estratégias tradicionais de regularização e ponderação de custos eram insuficientes para mitigar o forte desequilíbrio do *dataset*. Os modelos classificadores continuavam a demonstrar uma tendência persistente para confundir as classes menos representadas com a classe maioritária (*Lithiasis*), comprometendo o F1-score macro. Com o intuito de expandir ativamente a fronteira de decisão dos modelos, optou-se por introduzir uma estratégia de aumento de dados sintéticos baseada em Modelos Generativos, recorrendo a uma arquitetura Variational Autoencoder (VAE).

Para garantir que o VAE gerasse estruturas anatómicas e padrões de contraste realistas, cruciais na interpretação de imagens fluoroscópicas de CPRE, implementou-se uma variante avançada baseada em *Perceptual Loss*. A função de perda foi desenhada combinando o erro quadrático médio (MSE) ao nível

do pixel, a divergência de Kullback-Leibler (KLD) para a regularização do espaço latente, e uma perda perceptual baseada nas características extraídas por uma rede VGG-16 pré-treinada. Esta componente perceptual revelou-se determinante, impedindo que o gerador produzisse imagens excessivamente desfocadas e preservando a geometria dos ductos biliares e das estenoses.

A estratégia de amostragem foi aplicada com critérios metodológicos rigorosos:

- **Oversampling Exclusivo das Minoritárias:** O processo de geração sintética focou-se estritamente no reforço das classes *Biliary Leaks*, *Normal* e *Stricture*. Para cada uma das três classes minoritárias foram geradas 300 imagens sintéticas com dimensões de 128×128 píxeis. O número efetivamente injetado no treino foi ajustado: 300 imagens para *Biliary Leaks* (110 reais + 300 geradas = 410), 213 para *Normal* (197 reais + 213 geradas = 410) e 155 para *Stricture* (255 reais + 155 geradas = 410).
- **Isolamento dos Conjuntos de Avaliação:** As imagens sintéticas foram injetadas única e exclusivamente no conjunto de treino. Os conjuntos de validação e teste permaneceram estritamente puros, constituídos apenas pelas imagens reais e originais.

A Tabela 3 sumariza o impacto direto do aumento de dados por VAE no F1-score macro do conjunto de teste e validação para a *baseline* reproduzida.

Tabela 3. Impacto do aumento de dados com VAE no F1-score macro de teste e validação.

Modelo	Val f1-macro (nosso baseline)	Test F1-macro (nosso baseline)	VAL Macro-F1 com VAE	Test Macro-F1 com VAE
DeiT3-Small	0.355	0.361	0.439	0.532
DenseNET121	0.517	0.513	0.585	0.666
MobileNetV2	0.546	0.512	0.583	0.682
ResNet50	0.496	0.535	0.574	0.691

A análise comparativa dos resultados revela um ganho de desempenho transversal. Os ganhos observados em teste foram acompanhados por melhorias consistentes no conjunto de validação, sugerindo uma melhor capacidade de generalização dos modelos. O modelo *DeiT3-Small*, que demonstrava uma incapacidade crítica de convergência no cenário desequilibrado original, subiu para 0.439 na validação e 0.532 no teste. Melhorias igualmente sólidas foram observadas na *DenseNet121* (+15.3%), *MobileNetV2* (+16.9%) e *ResNet50* (+15.6%) em relação às respectivas *baselines* locais ao nível do teste.

Com o sucesso validado neste núcleo inicial de arquiteturas, a exploração foi estendida a um espectro mais amplo de modelos do estado da arte (Tabela 4).

Tabela 4. Resultados de modelos adicionais treinados com aumento de dados VAE.

Modelo	Parâmetros	VAL F1-macro com VAE	Teste F1-macro com VAE
ConvNeXt-Tiny	20,182,612	0.665	0.727
ConvNeXt-SMALL	49,457,764	0.632	0.603
Resnet_18	11,700,000	0.570	0.648
Resnet_34	21,800,000	0.575	0.532
Swin Transformer V2 Tiny	27,585,646	0.549	0.601
Swin Transformer V1 Tiny	27,522,430	0.524	0.643
EfficientNetV2-S	20,182,612	0.643	0.670
EfficientNet B0	4,007,548	0.515	0.674

Modelo	Parâmetros	VAL F1-macro com VAE	Teste F1-macro com VAE
EfficientNet B3	10,696,232	0.520	0.565
EfficientNet B5	28,348,980	0.519	0.608

O principal destaque desta abordagem experimental reside no comportamento do modelo ConvNeXt-Tiny. Além de registar o melhor desempenho no conjunto de validação (0.665), alcançou um F1-score macro de 0.727 no teste. Esta arquitetura convolucional moderna estabeleceu-se assim como um modelo altamente competitivo no *pipeline* do projeto, aproximando-se do desempenho fixado pela EfficientNet-B7 original (0.738), mas operando com uma fração significativamente menor de parâmetros e custo computacional.

5.5 Ensemble Ponderado Final

Para aproveitar os resultados dos modelos treinados com o aumento de dados pelo VAE descrito na secção anterior, a solução final foi construída a partir de uma sequência de *ensembles* ponderados. Primeiro, foi criado um *ensemble* inicial com quatro modelos treinados com as imagens sintéticas: EfficientNet-B7, DenseNet, MobileNetV2 e ResNet50. Esta combinação permitiu reduzir a dependência de uma única arquitetura e aproveitar padrões de aprendizagem distintos. O impacto desta configuração no desempenho pode ser consultado na Tabela 5 (Secção 6.1).

Como este *ensemble* já apresentava resultados estáveis, foram posteriormente testadas integrações incrementais com modelos adicionais treinados, tal como os anteriores, com imagens geradas pelo VAE. Primeiro, foi adicionado o ConvNeXt-Tiny através de um *blend* ponderado; depois, foi testada a adição do EfficientNet-B0, também com peso reduzido. Esta estratégia incremental permitiu avaliar o contributo de cada novo componente sem reconstruir todo o sistema de raiz, cada integração produziu uma melhoria progressiva no F1-score de validação e teste (ver Tabela 5).

Numa fase final, após confirmar que o EfficientNet-B0 acrescentava informação útil, foi testada uma reotimização direta dos pesos dos seis modelos. A previsão final passou então a ser obtida por *soft voting* ponderado:

$$P_{final} = \sum_{m=1}^6 w_m P_m$$

onde P_m representa o vetor de probabilidades produzido por cada modelo. Os pesos seleccionados com base no conjunto de validação foram: EfficientNet-B7 = **0.3722**, DenseNet = **0.0006**, MobileNetV2 = **0.1791**, ResNet50 = **0.0038**, ConvNeXt-Tiny = **0.3064** e EfficientNet-B0 = **0.1380**.

Esta reotimização mostrou que DenseNet e ResNet50 contribuíam de forma residual na configuração final, enquanto EfficientNet-B7, ConvNeXt-Tiny, MobileNetV2 e EfficientNet-B0 concentravam a maior parte do peso, o que é consistente com os resultados individuais de cada modelo reportados na Secção 5.4. Assim, a solução final reportada corresponde a um *ensemble* ponderado direto de seis modelos, sem mecanismos adicionais de *override*. Tal como referido na secção 5.2, foram ainda testados mecanismos especializados de correção sobre esta configuração final. O Biliary_Leaks_Specialist foi ativado em três imagens do conjunto de teste, mas não alterou nenhuma previsão, uma vez que o *ensemble* ponderado já classificava esses casos como Biliary_Leaks. O specialist Stricture/Lithiasis também foi avaliado para atacar a principal confusão observada na matriz de confusão, mas não foi ativado em nenhuma previsão final. Assim, a solução final reportada corresponde a um *ensemble* ponderado direto de seis modelos, sem mecanismos adicionais de *override*.




Fig 1: Solução final - Modelo

6 Resultados e Discussão

6.1 Resultados Finais

Tabela 5. Resultados finais das diferentes abordagens no conjunto de validação e teste.

Modelo	Val Macro-F1	Test Macro-F1
EfficientNet-B7 baseline	0.601	0.744
4-model ensemble + Biliary Specialist	0.679	0.762
ConvNeXt blend + Biliary Specialist	0.689	0.772
Hierarchical blend + EfficientNet-B0	0.694	0.787
Hierarchical blend + EfficientNet-B0 + Biliary Specialist + Stricture/Lithiasis Specialist	0.694	0.787
Direct 6-model weighted ensemble	0.714	0.788

A tabela evidencia uma melhoria progressiva entre as abordagens testadas. O *ensemble* inicial com *Biliary_Leaks Specialist* superou a *baseline EfficientNet-B7*, atingindo um *Test Macro-F1* de **0.762**. A integração posterior do *ConvNeXt-Tiny* aumentou esse valor para **0.772**, e a adição incremental do *EfficientNet-B0* permitiu atingir **0.787**.

A melhor solução foi obtida com a reotimização direta dos pesos dos seis modelos, alcançando *Val Macro-F1* de **0.714** e *Test Macro-F1* de **0.788**. Embora a melhoria no teste seja pequena face ao *blend* hierárquico anterior, também se verificou melhoria em validação, o que torna esta configuração a solução final mais consistente.

6.2 Análise por Classe

Tabela 6. F1-score no teste por classe do modelo final.

Classe	Test F1-score
<i>Biliary_Leaks</i>	0.727
<i>Lithiasis</i>	0.829
<i>Normal</i>	0.720
<i>Stricture</i>	0.877

A análise por classe mostra que o modelo final teve melhor desempenho em *Stricture* e *Lithiasis*, com *F1-scores* de **0.877** e **0.829** no teste, respetivamente. A classe *Normal* obteve um *F1-score* de **0.720** no teste, mantendo alguma confusão com *Lithiasis*.

A classe *Biliary_Leaks* continuou a ser a mais desafiante, com *F1-score* de **0.727** no teste. Apesar de não ser a classe com melhor desempenho, o resultado permanece competitivo tendo em conta o número reduzido de exemplos disponíveis no treino e no teste. A principal melhoria do *ensemble* final resulta sobretudo da melhor separação das classes *Stricture* e *Lithiasis*.

6.3 Matriz de Confusão

A matriz de confusão, apresentada na Fig. 2, confirma que o modelo final apresenta melhor desempenho em *Lithiasis* e *Stricture*, com 99/123 e 71/84 previsões corretas, respetivamente. A principal confusão continua a ocorrer entre *Stricture* e *Lithiasis*, embora o número de casos de *Stricture* classificados como *Lithiasis* tenha diminuído para 12. A classe Normal apresenta 36/43 acertos, sendo ainda confundida sobretudo com *Lithiasis*. A classe *Biliary_Leaks* mantém-se como a mais difícil: o modelo acerta 12/17 casos, mas classifica 5 como Normal, o que continua a representar o erro clinicamente mais sensível. No geral, a matriz confirma que a reotimização direta dos pesos melhora ligeiramente o desempenho global, mas não elimina as dificuldades associadas às classes minoritárias e aos padrões visualmente semelhantes. Do ponto de vista clínico, os erros de classificação nas classes mais críticas têm implicações distintas. Os 5 casos de *Biliary_Leaks* classificados como normal representam falsos negativos de elevada gravidade, uma fuga biliar não detetada pode evoluir para peritonite e sépsis, condições potencialmente fatais que exigem intervenção urgente. Da mesma forma, os 12 casos de *Stricture* classificados como *Lithiasis* podem conduzir a um plano terapêutico errado, dado que estenoses biliares de origem maligna requerem abordagem oncológica distinta da litíase. Estes erros sublinham que, em contexto de apoio à decisão clínica, a otimização do *F1-score* macro não é suficiente e seria necessário incorporar uma função de perda assimétrica que penalize mais fortemente os falsos negativos nas classes de maior risco, como *Biliary_Leaks* e *Stricture*.




Fig. 2. Matriz de confusão do modelo final no conjunto de teste

7 Interpretabilidade

7.1 Grad-CAM

A análise Grad-CAM foi aplicada a exemplos corretamente classificados e a um caso de erro, de forma a avaliar se o modelo estava a usar regiões visualmente relevantes para a decisão. Dentro dos exemplos corretos, é apresentado na Fig. 3 um exemplo de *Biliary_Leaks* e *Lithiasis*, onde as ativações aparecem concentradas em zonas internas da imagem, próximas de regiões com maior contraste, sugerindo que o modelo não depende apenas das bordas ou do fundo da imagem.

No exemplo incorretamente classificado, a ativação também surge localizada, mas conduz a uma previsão errada de *Normal* para uma imagem real de *Lithiasis*. De modo geral, os mapas Grad-CAM indicam que o modelo utiliza informação interna da imagem, embora a interpretabilidade também evidencie limitações em casos ambíguos.




Fig. 3. Visualização de mapas de ativação Grad-CAM - Exemplo 1.




Fig. 4. Exemplo de Grad-CAM num caso de erro: Lithiasis classificado como Normal – Exemplo 2.

7.2 Occlusion Sensitivity

A *Occlusion Sensitivity* foi utilizada como complemento ao Grad-CAM, permitindo avaliar o impacto da oclusão de diferentes regiões da imagem na confiança do modelo. Nos exemplos corretamente classificados de *Biliary_Leaks* e *Lithiasis*, presentes na Fig. 5, as zonas mais relevantes aparecem concentradas em regiões internas da imagem, o que sugere que o modelo utiliza informação visual associada ao conteúdo clínico da fluoroscopia.

No exemplo incorretamente classificado na Fig. 6, a região destacada também é localizada, mas conduz à previsão errada de *Normal* para uma imagem real de *Lithiasis*. De forma geral, a *Occlusion Sensitivity* confirma que o modelo não depende apenas das bordas da imagem, embora continue a revelar limitações em casos ambíguos.




Fig 5. Mapas de Occlusion Sensitivity para os exemplos analisados - Exemplo 1.




Fig. 6. Mapas de Occlusion Sensitivity para os exemplos analisados - Exemplo 2.

8 Conclusão e Trabalho Futuro

Neste trabalho foi reproduzida a *baseline* do *dataset* MIQR-CC e foram testadas várias estratégias para melhorar a classificação automática de imagens fluoroscópicas de CPRE. As estratégias simples de pré-processamento, como CLAHE e treino ponderado, não foram suficientes para melhorar a *baseline* de forma estável. Em contraste, a geração sintética com VAE permitiu treinar modelos adicionais competitivos, destacando-se o ConvNeXt-Tiny e o EfficientNet-B0.

Foram também explorados modelos especialistas para classes problemáticas, nomeadamente *Biliary_Leaks* e a confusão *Stricture/Lithiasis*. No entanto, a análise de impacto mostrou que estes mecanismos não alteravam as decisões finais na melhor configuração obtida, pelo que foram tratados como experiências complementares e não como componentes ativos da solução final.

A melhor solução foi um *ensemble* ponderado direto de seis modelos, combinando EfficientNet-B7, DenseNet, MobileNetV2, ResNet50, ConvNeXt-Tiny VAE e EfficientNet-B0 VAE. Esta abordagem alcançou um *Test* Macro-F1 de 0.7881, superando a *baseline* reproduzida localmente e a *baseline* original reportada. Como trabalho futuro, seria relevante validar o sistema com especialistas clínicos, melhorar a geração de imagens e, consequentemente, gerar um maior número de exemplos para as classes minoritárias.

Referências

1. Andrade, et al.: MIQR-CC: Multimodal Image Quality and Risk in ERCP and Colonoscopy dataset. (2023)
- 2.A. Andrade et al., "MIQR-CC-Dataset," GitHub, 2023. [Online]. Disponível em: <https://github.com/monicacmartins/MIQR-CC-Dataset>